




FemHealth Clinical AI

Relatório Técnico Final

Classificação tabular de padrões do WDBC com Machine Learning

TECH CHALLENGE • FASE 1

Álvaro Amorim de Oliveira Martins

FIAP • Pós Tech - IA para Devs • Turma 11IADT

Juiz de Fora - MG • 27/07/2026

Versão final revisada em 18/08/2026

Identificação e resumo executivo

Versão final pós-vídeo e pós-validação do repositório.

569

Registros no WDBC

97,37%

Acurácia final

30

Variáveis numéricas

97,62%

Recall maligno

455

Desenvolvimento

96,47%

F1 maligno

114

Holdout final

376

Testes aprovados

Autor: Álvaro Amorim de Oliveira Martins

Instituição: FIAP | Curso: Pós Tech - IA para Devs | Turma: 11IADT

Local e data do projeto: Juiz de Fora - MG, 27 de julho de 2026 | Revisão final: 18 de agosto de 2026

Repositório: github.com/alvaro-amorim/femhealth-clinical-ai

Vídeo de demonstração: youtu.be/ui-k60XdLRE

Resumo. O FemHealth Clinical AI implementa um fluxo reprodutível de classificação tabular do Breast Cancer Wisconsin Diagnostic (WDBC). As 30 entradas têm origem em imagens microscópicas digitalizadas de material de punção aspirativa por agulha fina (PAAF/FNA), mas o sistema recebe somente as medidas já estruturadas. O modelo final é um SVM RBF com StandardScaler, calibração sigmoid e limiar maligno de 0,51. No holdout de 114 registros houve 41 malignos corretamente classificados, 1 falso negativo, 2 falsos positivos e 70 benignos corretamente classificados.

Natureza acadêmica. O projeto não possui validade clínica, não indica exames e não substitui avaliação por profissional de saúde.

Conformidade com os entregáveis

Mapa objetivo entre o enunciado e os artefatos entregues.

Item	Status	Evidência
Link do repositório Git	Atendido	GitHub público com código, documentação, notebooks, artefatos e CI.
Código-fonte completo	Atendido	Disponível em src/femhealth e arquivos de entrada do projeto.
README com execução	Atendido	README contém instalação, FastAPI, Streamlit, testes e estrutura.
Dockerfile	N/A	Docker não foi utilizado nesta entrega.
Dataset ou link	Atendido	WDBC via Scikit-learn e referência ao UCI.
Resultados, prints e gráficos	Atendido	EDA, benchmark, holdout, explicabilidade, API e demonstração.
Relatório técnico	Atendido	EDA, pré-processamento, modelos, justificativas, resultados e crítica.
Vídeo <= 15 min	Atendido	Publicado no YouTube; duração final aproximada de 10min24s.

Cobertura do enunciado. O PDF concentra os itens exigidos para a Fase 1 e aponta para o repositório como fonte do código-fonte, README e artefatos de execução.

Navegação

1. Contexto e objetivo · 4

3.1 Correlação · 7

6. Ajuste e seleção · 10

9. Arquitetura · 13

12. Reprodutibilidade · 16

15. Referências e links · 19

2. Dataset e contrato · 5

4. Pré-processamento e protocolo · 8

7. Holdout final · 11

10. API, Swagger e interface · 14

13. Limitações e ética · 17

3. Análise exploratória · 6

5. Modelos e benchmark · 9

8. Explicabilidade · 12

11. Demonstração e simulador · 15

14. Conclusão e trabalhos futuros · 18

Contexto e objetivo do desafio

Classificação acadêmica de padrões tabulares relacionados ao câncer de mama.

O Tech Challenge da Fase 1 propõe uma solução inicial de IA para dados relacionados à saúde e segurança da mulher. A tarefa principal utiliza Machine Learning em dados estruturados; visão computacional aparece como extensão opcional.

O FemHealth restringe o escopo obrigatório à classificação tabular do WDBC, priorizando um protocolo auditável, reproduzível e claramente separado de qualquer alegação de uso clínico.

Problema formulado. Dadas 30 medidas numéricas de núcleos celulares previamente extraídas de imagem digitalizada de PAAF/FNA e organizadas segundo o contrato do WDBC, estimar o padrão de referência 0 = malignant ou 1 = benign.




Figura 1 - Etapas cronológicas do protocolo metodológico.

Objetivos específicos

- validar contrato explícito de dados e a ordem das 30 features;
- comparar cinco classificadores e justificar a seleção;
- proteger um holdout final de tuning, calibração, escolha de limiar e explicabilidade;
- avaliar recall e F1 da classe maligna, além de métricas complementares;
- persistir artefato versionado e expor inferência via API;
- apresentar explicabilidade global sem alegar causalidade ou relevância clínica isolada.

Dataset e contrato de dados

Breast Cancer Wisconsin Diagnostic - WDBC.

569

Registros

30

Features

212

Malignos

357

Benignos

0

Valores ausentes

2

Classes

A base é carregada por `sklearn.datasets.load_breast_cancer(as_frame=True)`. O contrato mantém as 30 variáveis numéricas na ordem canônica e valida quantidade de registros, distribuição das classes, tipos, duplicidade relevante e finitude.

Grupo	Qtd.	Definição
mean	10	Médias das medidas do núcleo celular.
error	10	Erros padrão associados às medidas.
worst	10	Média dos 3 maiores valores de cada medida.

Origem das variáveis e limite do sistema




Figura 2 - Origem das 30 variáveis e início do escopo implementado.

As features descrevem características dos núcleos celulares presentes em imagem microscópica digitalizada de material obtido por PAAF/FNA de uma massa mamária. O FemHealth não executa a coleta, digitalização, segmentação ou extração dessas medidas.

Contrato de classes. Classe 0 = malignant; classe 1 = benign. A implementação localiza explicitamente a probabilidade associada à classe 0, em vez de assumir que a classe positiva seja 1.

3

Análise exploratória - qualidade e distribuição

Estrutura da base antes da modelagem.




Figura 3 - Distribuição das classes.




Figura 4 - Distribuições selecionadas por classe.

A base contém 357 registros benignos (62,7%) e 212 malignos (37,3%). O desbalanceamento é moderado e foi considerado com split estratificado, métricas sensíveis à classe e `class_weight="balanced"` nos modelos ajustados.

Raio, pontos côncavos e área mostram diferenças de distribuição entre as classes, mas também existe sobreposição. Nenhuma variável isolada deve ser interpretada como regra determinística.

Verificação	Resultado
Valores ausentes	Nenhum valor nulo nas 30 features.
Duplicidade	Nenhuma duplicidade relevante detectada pelo contrato.
Tipos	Variáveis numéricas compatíveis com modelagem.
Escalas	Grandezas em escalas distintas; padronização necessária para modelos sensíveis.

Correlação e padrões relevantes

Associação estatística, não causalidade.




Figura 5 - Correlação das features com o alvo.




Figura 6 - Correlação entre features selecionadas.

Como o alvo usa 1 para benigno, correlações negativas indicam associação com padrões malignos. Medidas ligadas a pontos côncavos, perímetro, raio e área apresentam alta associação absoluta com a classe.

A matriz entre features mostra forte redundância geométrica. Esse fato é relevante para a explicabilidade: ao permutar uma feature correlacionada, outra pode preservar parte da informação e reduzir a queda individual da métrica.

Interpretação responsável. Correlação descreve associação no dataset. Não demonstra causalidade, mecanismo biológico nem relevância clínica independente.

Pré-processamento e protocolo experimental

Holdout preservado até a seleção estar congelada.

O pipeline evita transformações globais antes da validação. Para modelos sensíveis à escala, StandardScaler fica dentro do Pipeline do Scikit-learn e é ajustado somente nos dados de treinamento de cada fold. Árvores e Random Forest não exigem padronização.

Conjunto	Registros	Malignos	Benignos	Proporção maligna
Desenvolvimento	455	170	285	37,36%
Teste final	114	42	72	36,84%




Figura 7 - Separação cronológica do desenvolvimento e holdout.

1. Divisão estratificada 80/20 com `random_state=42`.
2. Benchmark em validação cruzada estratificada de 5 folds no desenvolvimento.
3. Ajuste dos três candidatos selecionados com refit orientado por recall maligno.
4. Probabilidades out-of-fold, calibração e análise de limiar.
5. Congelamento de modelo, calibração e limiar antes do holdout.
6. Avaliação única do teste final e persistência dos resultados.

Proteção do holdout. O teste final não participou de benchmark, tuning, calibração, escolha de limiar ou explicabilidade. Após a avaliação única, nenhuma decisão de modelo foi alterada para melhorar o resultado.

Modelos avaliados e benchmark

Cinco candidatos comparados somente no desenvolvimento.




Figura 8 - Benchmark baseline em validação cruzada.

Modelo	Acurácia	Recall mal.	F1 mal.	FN OOF	FP OOF
Regressão Logística	97,80%	96,47%	97,03%	6	4
Random Forest	96,26%	95,88%	95,06%	7	10
SVM	96,92%	95,29%	95,83%	8	6
KNN	96,26%	92,94%	94,90%	12	5
Árvore de Decisão	91,65%	92,35%	89,19%	13	25

A Regressão Logística apresentou o melhor baseline de acurácia e F1. A seleção, porém, não encerrou nessa etapa: o projeto também avaliou tuning, calibração e qualidade probabilística antes de congelar o modelo final.

Candidatos ajustados. Regressão Logística, Random Forest e SVM seguiram para ajuste de hiperparâmetros. KNN e Árvore permaneceram como comparadores do benchmark.

Ajuste, calibração e seleção final

Três modelos ajustados, uma configuração congelada.

Modelo ajustado	Configuração principal	Recall mal.	ROC AUC
Regressão Logística	C=0,1; balanceada; liblinear	97,65%	99,21%
Random Forest	200 árvores; balanceada; max_features=sqrt	97,06%	99,16%
SVM	RBF; C=1; gamma=scale; balanceada	97,06%	99,63%




Figura 9 - Qualidade das probabilidades no desenvolvimento.

A variante svm_sigmoid apresentou Brier Score aproximado de 0,0210, log loss de 0,0802, ROC AUC de 0,9949 e average precision de 0,9936 no desenvolvimento.

Seleção congelada. SVM com kernel RBF, StandardScaler no pipeline, class_weight="balanced", calibração sigmoid e limiar maligno 0,51. A classe 0 foi mantida explicitamente como classe de interesse.

O limiar 0,51 foi escolhido a partir de probabilidades out-of-fold antes da abertura do holdout. A regra buscou recall maligno elevado sem deteriorar excessivamente a especificidade benigna.

Avaliação final do holdout

Avaliação única após seleção congelada.

97,37%

Acurácia

95,35%

Precision maligno

97,62%

Recall maligno

96,47%

F1 maligno

97,22%

Especificidade benigna

99,40%

ROC AUC maligno




Figura 10 - Métricas principais do teste final.




Figura 11 - Matriz de confusão.

Foram corretamente classificados 41 dos 42 registros malignos e 70 dos 72 benignos. O único falso negativo corresponde a um registro maligno previsto como benigno; os dois falsos positivos são registros benignos previstos como malignos.

Leitura crítica. O holdout contém apenas 42 malignos; cada erro altera sensivelmente as métricas. O resultado é forte no protocolo acadêmico, mas uma única divisão interna não comprova desempenho em outras populações ou ambientes.

Métricas complementares: balanced accuracy 97,42%; average precision maligno 99,18%; Brier Score 0,0278; log loss 0,0950.

Explicabilidade global

Importância por permutação: dependência preditiva, não causalidade.




Figura 12 - Importância média por permutação com validação cruzada.

455

Amostras

5

Folds

10

Repetições/feature

1.500

Observações

99,63%

ROC AUC médio

0,0040

Desvio-padrão

Rank	Feature	Importância média	Desvio-padrão
1	worst texture	0,005593	0,004609
2	radius error	0,002023	0,002566
3	worst radius	0,001992	0,003237
4	worst area	0,001775	0,003215
5	worst concave points	0,001672	0,002882

A análise foi calculada em cada fold do desenvolvimento: modelo ajustado no subconjunto de treino, baseline no fold de validação e 10 permutações por feature. O holdout não foi utilizado.

Limitação do método. Importância por permutação mede dependência preditiva. Não prova causalidade, não identifica relevância clínica isolada e pode ser compartilhada entre features correlacionadas.

Arquitetura da solução

Separação entre aquisição externa, artefatos congelados, API e interface.




Figura 13 - Arquitetura final e limite de escopo.

Camada	Responsabilidade
Origem externa	PAAF/FNA, digitalização da lâmina, análise dos núcleos e extração das 30 medidas.
Dados e desenvolvimento	WDBC, contrato, split, benchmark, tuning, calibração e avaliação.
Artefatos congelados	Jolbib, metadados, resultados, explicabilidade e casos de demonstração.
FastAPI	Carrega artefatos no lifespan e expõe contratos HTTP.
Streamlit	Interface em português que consome somente a API.
Testes e CI	Validação automática de contratos, artefatos, endpoints e interface.

O limite do sistema começa nas 30 features tabulares. Dentro da aplicação, a FastAPI não treina modelos nem recalcula explicabilidade por requisição; o Streamlit não lê Jolbib nem reports diretamente.

Resumo operacional. FastAPI carrega modelo, explicabilidade e casos de demonstração no lifespan. Streamlit consome apenas endpoints HTTP.

API, Swagger e interface

Documentação executável e contrato explícito de inferência.




Figura 14 - Swagger com exemplo das 30 features canônicas.



Figura 15 - Interface Streamlit consumindo a API.

A FastAPI expõe documentação interativa em /docs. Após a melhoria final do OpenAPI, o POST /predict apresenta um exemplo completo das 30 features canônicas, em vez de chaves genéricas additionalProp. Isso torna o contrato visível e testável durante a demonstração.

Contrato de inferência. O endpoint exige exatamente 30 chaves canônicas, rejeita chaves ausentes ou adicionais, booleanos, textos, nulos, NaN e infinito. A ordem é normalizada antes da inferência.

Endpoints finais

- GET /health - estado da API e artefato carregado;
- GET /model - configuração congelada e metadados seguros;
- POST /predict - inferência acadêmica;
- GET /explainability e /explainability/plot - resultados persistidos;
- GET /demo-cases - casos congelados para apresentação.

Separação de responsabilidades. A interface não acessa o modelo diretamente; toda inferência passa pela FastAPI via HTTP.

Demonstração e simulador

Exemplos reais do holdout e contrato manual das 30 entradas.




Figura 16 - Casos congelados de demonstração.




Figura 17 - Resultado do simulador para um registro do holdout.

Caso	Índice	Referência	Resultado
demo-01	256	Maligno	Acerto
demo-02	428	Benigno	Acerto
demo-03	501	Maligno	Acerto
demo-04	363	Benigno	Divergência
demo-05	564	Maligno	Acerto
demo-06	464	Benigno	Acerto
demo-07	358	Benigno	Acerto
demo-08	343	Maligno	Acerto

Os oito casos são os primeiros registros na ordem congelada do holdout; a seleção não considerou acerto, probabilidade ou dificuldade. O placar observado é 7 acertos e 1 divergência (87,50%), valor que não substitui a acurácia oficial de 97,37% nos 114 registros.

O simulador manual usa o mesmo POST /predict. As 30 entradas são medidas nucleares do contrato WDBC e não informações normalmente digitadas por paciente. No vídeo foi utilizado um registro real do holdout para demonstrar o fluxo ponta a ponta.

Reprodutibilidade, testes e qualidade

Estado final validado após a melhoria do Swagger.

376 Testes aprovados	Ruff aprovado Lint	3.11 Python
1.9.0 Scikit-learn	1.0.0 Artefato	Não Holdout reaberto

Instalação e validação

Etapas	Comando
Criar ambiente	<code>py -3.11 -m venv .venv</code>
Instalar	<code>python -m pip install -e ".[dev,analysis]"</code>
Lint	<code>python -m ruff check .</code>
Testes	<code>python -m pytest -q</code>
FastAPI	<code>python -m uvicorn femhealth.api:app --host 127.0.0.1 --port 8000</code>
Streamlit	<code>python -m streamlit run streamlit_app.py</code>

Na validação final da PR de documentação Swagger, Ruff passou e a suíte completa terminou com 376 testes aprovados. O smoke test Streamlit afetado também foi executado três vezes isoladamente com sucesso.

Integridade do modelo. SHA-256 do Joblib: CC43CEC3BA58C5A4950217E80C8B286B0E7DB501FF663BA9BE9F91DF1F4B05B5. O artefato final não foi alterado pela melhoria do Swagger.

O artefato foi treinado somente com os 455 registros de desenvolvimento. O repositório mantém Model Card, arquitetura, documentação acadêmica, uso responsável e transparência sobre apoio de IA generativa.

Limitações, ética e uso responsável

Resultados fortes no protocolo não equivalem a validade clínica.

- dataset pequeno, histórico e de origem específica;
- ausência de validação externa e prospectiva;
- 30 medidas tabulares sem contexto clínico completo;
- ausência de módulo validado para aquisição, digitalização, segmentação e extração das features;
- possível mudança de desempenho em outras populações, equipamentos e protocolos;
- risco de falsos negativos e falsos positivos;
- probabilidades calibradas somente dentro do protocolo acadêmico;
- correlação e importância por permutação não comprovam causalidade;
- resultado não generalizável para saúde feminina em geral.

Usos proibidos. Diagnóstico ou triagem clínica real, indicação de PAAF/FNA ou outro exame, orientação de tratamento, decisão médica autônoma, uso emergencial, substituição de profissional ou implantação em produção médica.

Antes de qualquer estudo clínico seriam necessários aprovação ética, governança de dados, validação externa, avaliação prospectiva, análise de viés, segurança, participação de profissionais qualificados e validação independente do fluxo anterior ao modelo.

O repositório usa dados públicos e não implementa banco de dados de pacientes. O código atual não comprova conformidade com LGPD, HIPAA ou outras normas regulatórias.

Conclusão e trabalhos futuros

Entrega final consolidada; próximos passos passam a ser pesquisa, não tarefas pendentes.

O FemHealth Clinical AI consolidou um fluxo completo de Machine Learning tabular com separação metodológica entre desenvolvimento e avaliação. Cinco modelos foram comparados, três ajustados, e a configuração final foi congelada antes da avaliação única do holdout.

O SVM RBF calibrado por sigmoid alcançou 97,37% de acurácia, 97,62% de recall maligno e 96,47% de F1 maligno. A matriz final registrou 41 verdadeiros malignos, 1 falso negativo, 2 falsos positivos e 70 verdadeiros benignos.

Além da modelagem, a entrega inclui artefato versionado, FastAPI, Swagger documentado, interface Streamlit, explicabilidade global, casos congelados de demonstração, simulador, notebooks, documentação acadêmica, 376 testes automatizados e vídeo publicado.

Conclusão central. Os resultados são tecnicamente consistentes com o protocolo executado. Não estabelecem validade clínica, não validam a etapa de aquisição/extração das variáveis e não autorizam uso em contexto real.

Possíveis trabalhos futuros

- avaliação em conjunto externo preservado;
- pipeline independente de visão microscópica para segmentação e extração reprodutível das 30 medidas;
- análise de estabilidade, viés e calibração em populações distintas;
- deploy público controlado apenas para demonstração;
- extensão experimental de visão computacional sem reutilizar o holdout conhecido.

Referências e links da entrega

Fontes técnicas, repositório e vídeo final.

1. FIAP. Tech Challenge - Fase 1. Documento de orientação da atividade, 2026.
2. UCI Machine Learning Repository. Breast Cancer Wisconsin (Diagnostic) Dataset.
3. WOLBERG, W. H.; STREET, W. N.; MANGASARIAN, O. L. Breast cytology diagnosis with digital image analysis. *Analytical and Quantitative Cytology and Histology*, 15(6), 396-404, 1993. PMID: 8297430.
4. WOLBERG, W. H.; STREET, W. N.; MANGASARIAN, O. L. Machine learning techniques to diagnose breast cancer from image-processed nuclear features of fine needle aspirates. *Cancer Letters*, 77(2-3), 163-171, 1994. DOI: 10.1016/0304-3835(94)90099-X.
5. Scikit-learn. `load_breast_cancer`; `CalibratedClassifierCV`; Permutation feature importance.

Repositório do projeto

<https://github.com/alvaro-amorim/femhealth-clinical-ai>



Vídeo de demonstração

<https://youtu.be/ui-k60XdLRE>



Links adicionais

Dataset UCI: <https://archive.ics.uci.edu/dataset/17/breast-cancer-wisconsin-diagnostic>

Scikit-learn - dataset: https://scikit-learn.org/stable/modules/generated/sklearn.datasets.load_breast_cancer.html

Scikit-learn - calibração:

<https://scikit-learn.org/stable/modules/generated/sklearn.calibration.CalibratedClassifierCV.html>

Scikit-learn - importância por permutação: https://scikit-learn.org/stable/modules/permutation_importance.html

Transparência sobre uso de IA. IA generativa apoiou planejamento, estruturação inicial de código, elaboração de testes, revisão e documentação. Os resultados quantitativos vieram de execuções, artefatos e validação humana. A responsabilidade final pela entrega permanece com o autor.

Declaração final. Este documento descreve um exercício acadêmico de engenharia de dados, modelagem, inferência e documentação responsável. O sistema recebe medidas nucleares já estruturadas; não executa o procedimento citológico nem o processamento da imagem de origem. Não se trata de solução clínica.